
Accidentes de Tráfico en Madrid – 2010 – 2019

Edicion 18: Master en
Data Science

Eva Sánchez Palomo



1. Introducción	2
2. Recursos utilizados	2
3. Extracción de los datos	2
3.1. Origen	2
3.2. Características	3
3.3. Estructura	3
3.4. Otras fuentes de datos.....	4
4. Análisis del DataSet	4
4.1. Características del accidente.....	4
1.2. Características de las Víctimas	6
5. Predicción del número de accidentes	8
5.2. Serie Temporal.....	11
5.3. Modelo estacionario	14
5.4. Efecto Covid en la serie temporal.....	16
6. Visualización de los puntos de concentración de accidentes	17
6.1. Visualización de los puntos de concentración de accidentes	18
6.2. Visualización de la localización de radares.....	19
6.3. Visualización conjunta de los puntos de concentración de accidentes y radares	20
7. Conclusiones.....	20

1. Introducción

Este Trabajo de Fin de Máster, tiene como objetivo analizar la base de datos de accidentes de tráfico del ayuntamiento de Madrid desde 2010 hasta 2019, de tres maneras:

- Con un análisis inicial exploratorio con el fin de obtener información de nuestro data set.
- Realizando una predicción del número de accidentes mediante el uso de series temporales. Además de evaluar el impacto del Covid en dicha predicción.
- Visualización de los puntos de concentración de accidentes mortales en Madrid y su cruce con la localización de los radares.

2. Recursos utilizados

Los programas o librerías utilizados han sido los siguientes:

- Python:
 - Pandas
 - Numpy
 - Pmdarima
 - Datetime
 - Matplotlib
 - Geocoder
 - Folium
- Tableau
- Google API Geocoding

3. Extracción de los datos

Primeramente y de manera breve, explicaremos cual es el origen, estructura y características del Dataset.

3.1. Origen

Los datos se han extraído del portal de datos de ayuntamiento de Madrid (link):

<https://datos.madrid.es/portal/site/egob/menuitem.c05c1f754a33a9fbe4b2e4b284f1a5a0/?vgnextoid=7c2843010d9c3610VgnVCM2000001f4a900aRCRD&vgnextchannel=374512b9ace9f310VgnVCM100000171f5a0aRCRD&vgnextfmt=default>).

Donde están las BBDD por año, desde el año 2010 a 2019 y parte del 2020. La información se ha descargado en un csv por año e introducido en Python para su tratamiento, uniéndolas posteriormente en un único DataSet de 2010 a 2019.

El DataSet de lo ocurrido hasta mayo de 2020 se utilizará en un punto concreto de este análisis, posteriormente veremos para que.

3.2. Características

Importante es, tener en cuenta que desde 2010 a 2018, las bases de datos son homogéneas tanto en estructura, como en siniestros tenidos en cuenta (solo tenemos en cuenta siniestros con heridos)

Sin embargo, en 2019, la BBDD es ligeramente diferente en estructura y también se tiene en cuenta siniestros sin heridos (cosa que en los datasets de años anteriores no).

Es por ello, que se utilizará un código que unirá como una única BBDD, las BBDD de accidentes de 2010 a 2018 y posteriormente habiendo utilizado otro código se unirá la BBDD de 2019.

Tenemos en cuenta además, que eliminaremos de 2019 los accidentes en los que solo hay ilesos, porque sin eliminarlos, la información no será homogénea y no podremos hacer análisis de la información correctos.

3.3. Estructura

Tendremos la siguiente estructura, con las siguientes columnas:

- No_Parte -> Identificador del accidente.
- Fecha
- Hora
- Dirección
- Distrito
- Tipo_Accidente -> Caída ciclomotor, Colisión doble, Atropello, Choque con objeto fijo, Otras causas, Colisión múltiple, No asignado, Caída motocicleta, Vuelco, Caída viajero bus, Caída bicicleta, Caída vehículo 3 ruedas
- Tipo_Vehiculo -> Ciclomotor, Turismo, Bicicleta, Motocicleta, Camión, Furgoneta, No asignado, Veh.3 ruedas, Varios, Auto-taxi, Autobús-autocar, Ambulancia
- Tipo_Persona -> Conductor, Pasajero, Peatón, No asignado, Testigo
- Tramo_Edad ->
- Sexo-> 0-> Hombre,1->Mujer,2-> No asignado
- Lesividad ->0-> Ileso, 1-> Leve, 2-> Grave, 3-> Muerto, 4-> No asignado
- Dia_Semana
- CPFA_Seco -> Condiciones ambientales Seco (0 -> No, 1-> Si)
- CPFA_Granizo-> Condiciones ambientales Granizo (0 -> No, 1-> Si)
- CPFA_Nieve-> Condiciones ambientales Nieve (0 -> No, 1-> Si)
- CPFA_Lluvia-> Condiciones ambientales Lluvia (0 -> No, 1-> Si)
- CPFA_Hielo-> Condiciones ambientales Hielo (0 -> No, 1-> Si)
- CPFA_Niebla-> Condiciones ambientales Niebla (0 -> No, 1-> Si)
- CPSV_Mojada -> Condiciones de la calzada Mojada (0 -> No, 1-> Si)
- CPSV_Aceite-> Condiciones de la calzada Aceite (0 -> No, 1-> Si)
- CPSV_Barro-> Condiciones de la calzada Barro (0 -> No, 1-> Si)
- CPSV_Grava_Suelta-> Condiciones de la calzada Suelta (0 -> No, 1-> Si)
- CPSV_Hielo -> Condiciones de la calzada Hielo (0 -> No, 1-> Si)
- CPSV_Seca_Y_Limpia -> Condiciones de la calzada Seca y Limpia (0 -> No, 1-> Si)

Nota: las variables CPFA y CPSV aunque fueron tratadas, finalmente no se utilizan en el estudio

3.4. Otras fuentes de datos

En dos determinados puntos del estudio necesitaremos de las siguientes fuentes de datos:

- En el punto 3.1.3. Número de accidentes por distrito, se ha necesitado el archivo shp del portal de datos de ayuntamiento de Madrid, que se encuentra en el siguiente link: <https://datos.madrid.es/portal/site/egob/menuitem.c05c1f754a33a9fbe4b2e4b284f1a5a0/?vgnextoid=46b55cde99be2410VgnVCM1000000b205a0aRCRD&vgnnextchannel=374512b9ace9f310VgnVCM100000171f5a0aRCRD&vgnextfmt=default>. Descargando el archivo: 'Distritos en formato geográfico' y utilizando el archivo: 'Distritos.shp' en Tableau.
- En el punto 5.2. Visualización de la localización de radares, se ha necesitado el archivo de Excel del portal de datos de ayuntamiento de Madrid: <https://datos.madrid.es/portal/site/egob/menuitem.c05c1f754a33a9fbe4b2e4b284f1a5a0/?vgnextoid=4678f7de62435510VgnVCM2000001f4a900aRCRD&vgnnextchannel=374512b9ace9f310VgnVCM100000171f5a0aRCRD&vgnextfmt=default>

4. Análisis del DataSet

Antes de profundizar en la predicción del número de accidentes y en la visualización de los puntos de concentración, se ha hecho un análisis inicial, con el fin de conocer mejor el DataSet, utilizando el programa Tableau.

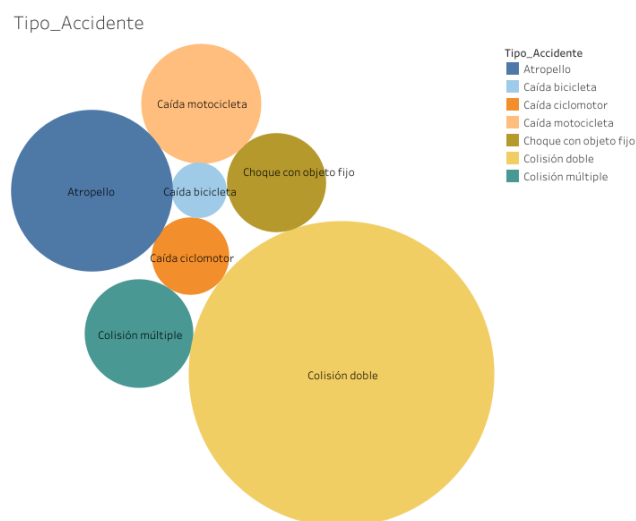
Dicho análisis se ha dividido en dos dependiendo de la información analizada:

- Info de las características del accidente
- Info de las características de la víctima

El número de víctimas ha sido de 266.424 y de accidentes ha sido de 97.513.

4.1. Características del accidente


4.1.1. Tipo de Accidente



Nota: Algunos tipos de accidente no aparecen en el gráfico, porque apenas tenían frecuencia.


Vemos que con muchísima diferencia la mayoría de los accidentes son colisiones dobles (54.148 de 97.513), seguido de atropellos.

1.1.1. Hora del Accidente




Con respecto a la hora en la que ocurren los accidentes hay ligero pico entre las 14.00 y las 15.00 horas, aunque se mantiene bastante regular a lo largo del día.

1.1.2. Día de la semana



El día que ocurren más accidentes es el viernes, seguido del resto de días de entre semana. El fin de semana es cuando menos accidentes ocurren.

1.1.3. Número de accidentes por distrito




Los distritos que concentran más accidentes son: Salamanca, Chamartín, Ciudad Lineal y Centro.

1.2. Características de las Víctimas

1.2.1. Tipo de Víctima

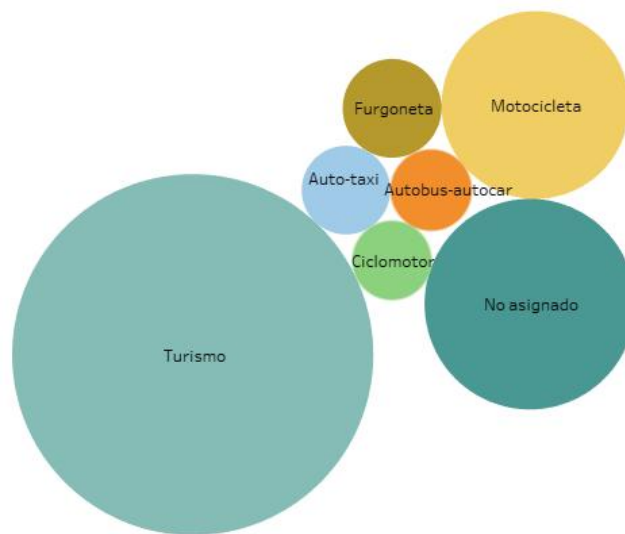
Tipo_Víctima



Como es lógico, en nuestro dataset, cuando ocurre un accidente, la mayoría de las personas involucradas, son conductores.

1.2.2. Tipo de Vehículo

Tipo_Vehiculo

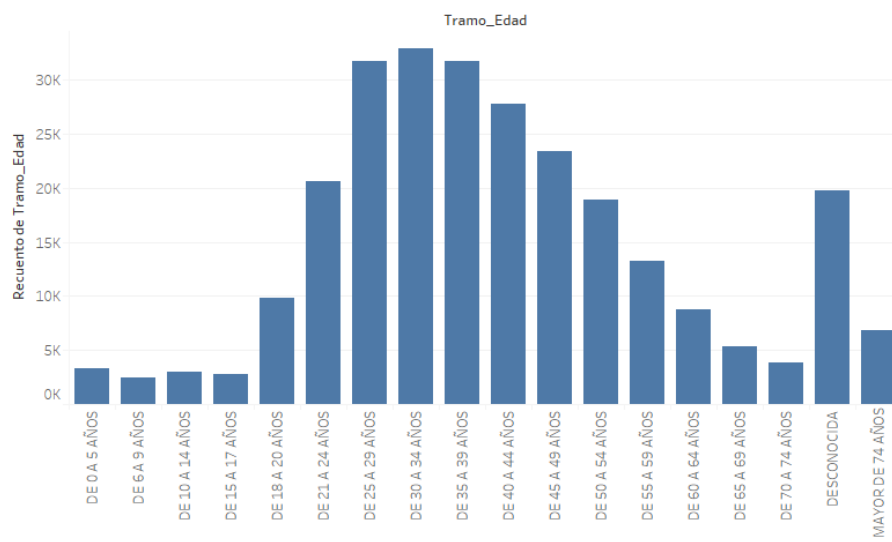


Nota: Se han excluido algunos tipos de vehículos de los gráficos porque apenas tenían frecuencia.

Por muchísima diferencia, en la mayoría de los siniestros están implicados turismos.

1.2.3. Tramo de edad

Tramo de edad



Vemos que hay un crecimiento en el número de accidentes por tramo de edad, llegando al pico entre los 30 y los 34 años. A partir de ahí, el número de víctimas va disminuyendo según aumenta la edad.


5. Predicción del número de accidentes

El estudio que se ha hecho sobre la predicción del número de accidentes se ha dividido en tres puntos:

- Análisis de la evolución del número de accidentes
- Predicción del número de accidentes de tráfico. Construyendo un modelo de serie temporal que usa todo el histórico de número de accidentes, desde 2010 a 2019. Sin transformar y transformando la serie a estacionaria.
- Predicción añadiendo a la serie de 2010 a 2019, los datos de los dos primeros meses de 2020. Para después, comparar la predicción de hasta febrero de 2020 con el número de accidentes que ocurrieron durante el confinamiento (marzo, abril y mayo de 2020).

5.1. Análisis de la serie

Visualizamos en la siguiente figura, la frecuencia de los partes desde 2010 a 2019:




Observando el gráfico anterior podemos observar:

- El número de partes va creciendo ligeramente de 2010 a 2018. Dicho crecimiento, podría darse por varias causas, por ejemplo:
 - El registro de accidentes de la base de datos ha mejorado y en años más antiguos - probablemente no se tenía registro de todos los accidentes que afectan al patrimonio o tenían heridos.
 - Ha crecido el número de vehículos en circulación en Madrid y por lo tanto, hay más accidentes.
 - Simplemente, han aumentado el número de accidentes.

Por desgracia, con los datos que tenemos en esta BBDD no podemos saber la causa del aumento del número de accidentes.


5.1.1. Análisis del comportamiento de la serie

5.1.1.1. Tendencia



Observamos que la serie sigue una tendencia creciente, salvo entre 2012 y 2013. El hecho de que la serie tenga una tendencia creciente, ya nos dice que la serie no es estacionaria, porque su media no es constante.



5.1.1.2. Estacionalidad



Detectamos muy fácilmente que la serie es estacional de manera anual.

5.1.2. Función de Autocorrelación

La función de autocorrelación, es la autocorrelación entre los valores de las series que se encuentran a k intervalos de distancia. Es decir, como el valor que toma un determinado punto se ve correlacionado con otro que está en otro punto temporal de la serie.




Observamos lo siguiente:

- Podemos observar, que hay un cierto patrón en la autocorrelación, ya que cada aproximadamente 6 periodos la autocorrelación sube. Esto es debido a la estacionalidad que hemos visto anteriormente.

5.1.3. Función de autocorrelación parcial (PACF)

El coeficiente de autocorrelación parcial, lo que hace es comparar lags, pero elimina del análisis la relación entre los lags intermedios. Es decir, para analizar la correlación entre el periodo 1 y el periodo 3, no se tiene en cuenta el valor del periodo 2.



Podemos obtener las siguientes conclusiones:

- Se ve claramente un descenso de autocorrelación parcial, según comparamos diferentes lags con intervalo temporal mayor.
- Apreciamos, que cada 6 o 7 meses, la autocorrelación parcial aumenta. Esto indica el comportamiento estacional de la serie.

5.2. Serie Temporal

5.2.1. SARIMA

Antes hemos podido intuir que nuestro modelo no es estacionario. No obstante, vamos a probar como sería su predicción. Para ello, vamos a utilizar los modelos SARIMA. Como vimos en clase hay tres tipos de modelos ARIMA:

- Los Autoregresivos - $AR(p)$
- Los de medias móviles - $MA(q)$
- Combinación de los dos anteriores - $ARMA(p,q)$
- Combinación de $AR(p) + d$ (n° de veces que se va a diferenciar la serie) + $MA(q)$

También tenemos que tener en cuenta que el modelo es estacional y por eso nuestro modelo es SARIMA. Con el fin de saber qué modelo puede predecir de manera más precisa el n° de partes y por lo tanto, accidentes de tráfico. Vamos a utilizar los valores AIC (Akaike Information Criterion) y BIC (Bayesian Information Criterion).

El modelo que mejor puede predecir la serie temporal es SARIMA(1,1,1)x(1,0,1,12).

```


=====
SARIMAX Results
=====
Dep. Variable:          No_Parte      No. Observations:      120
Model:                 SARIMAX(1, 1, 1)x(1, 0, 1, 12)      Log Likelihood        -653.523
Date:                  Sat, 25 Apr 2020      AIC                  1317.046
Time:                  17:49:27      BIC                  1330.942
Sample:                01-01-2010      HQIC                 1322.689
                    - 12-01-2019

Covariance Type:      opg
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ar.L1          0.0434      0.056      0.774      0.439      -0.067      0.153
ma.L1         -0.9368      0.063     -14.856      0.000      -1.060     -0.813
ar.S.L12       0.9991      0.011     94.514      0.000      0.978      1.020
ma.S.L12      -0.9341      0.360     -2.595      0.009      -1.640     -0.229
sigma2       2588.4309     863.038      2.999      0.003     896.907    4279.955
=====
Ljung-Box (Q):          34.53      Jarque-Bera (JB):          0.07
Prob(Q):                0.71      Prob(JB):                0.97
Heteroskedasticity (H): 2.02      Skew:                   -0.03
Prob(H) (two-sided):    0.03      Kurtosis:                3.10
=====

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).


```

Vamos a ver como predeciría nuestro modelo la serie temporal que ya tenemos:



Vemos, que el modelo SARIMA, predice bastante bien la serie.

Veremos a continuación, como predice para los siguientes 60 meses siguientes:



5.2.2. Transformaciones y Test de Dicky Fuller

El test de Dicky-Fuller aumentado nos ayudara a confirmar si una serie es estacionaria o no. La hipótesis nula de este test es que la serie temporal no es estacionaria. Este test tiene varios outputs, pero los que más nos interesan son:

- El primer valor, cuanto más negativo sea, más probable será que la serie sea estacionaria.
- El segundo valor, es un p-valor y si el valor, es menos que 0,05 podremos rechazar la hipótesis nula y afirmar que la serie es estacionaria.

Primeramente, haremos el test para la serie temporal sin transformar:

```
(-0.26575162311531497, 0.9302168142075058)
```

Vemos que con la serie temporal sin transformar, no podemos rechazar la hipótesis nula y por lo tanto, la serie no es estacionaria.

Haremos las siguientes transformaciones:

- Diferencia con lag anterior
- Transformación logarítmica
- Porcentaje de cambio
- Box-Cox

Comparando los test de Dicky-Fuller de las anteriores transformaciones, llegamos a la conclusión, de que la transformación que hace que nuestro modelo pueda cumplir mejor el criterio de serie estacionaria es la diferencia con el lag anterior.


```
(-10.034372675603048, 1.5546426437587747e-17)
```

5.3. Modelo estacionario

Hacemos la predicción del modelo con la transformación que hace que nuestra serie temporal sea estacionaria.


Dep. Variable:	y	No. Observations:	119			
Model:	SARIMAX(1, 0, 3)x(1, 0, [1], 12)	Log Likelihood	-651.589			
Date:	Sun, 12 Jul 2020	AIC	1319.177			
Time:	17:05:41	BIC	1341.410			
Sample:	0	HQIC	1328.205			
	- 119					
Covariance Type:	opg					
	coef	std err	z	P> z	[0.025	0.975]
intercept	0.0201	0.056	0.358	0.721	-0.090	0.130
ar.L1	-0.9997	0.003	-356.665	0.000	-1.005	-0.994
ma.L1	0.0591	0.242	0.244	0.807	-0.415	0.533
ma.L2	-0.9982	0.193	-5.173	0.000	-1.376	-0.620
ma.L3	-0.0574	0.104	-0.552	0.581	-0.261	0.146
ar.S.L12	0.9935	0.018	54.249	0.000	0.958	1.029
ma.S.L12	-0.8458	0.205	-4.123	0.000	-1.248	-0.444
sigma2	2825.6036	0.000	1.93e+07	0.000	2825.603	2825.604
Ljung-Box (Q):	33.46	Jarque-Bera (JB):	0.13			
Prob(Q):	0.76	Prob(JB):	0.94			
Heteroskedasticity (H):	1.75	Skew:	0.00			
Prob(H) (two-sided):	0.08	Kurtosis:	2.84			

A continuación, vemos como el modelo que hemos utilizado, predeciría nuestra serie temporal:

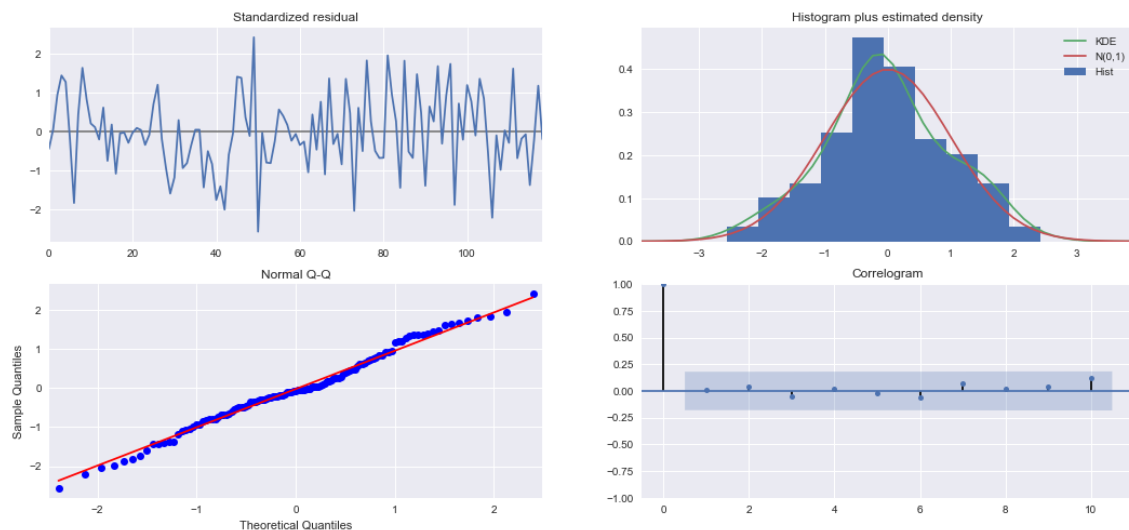


Vemos que nuestro modelo predice bastante bien el comportamiento de la serie.

Hacemos la predicción de nuestra serie temporal inicial. Es decir, hacemos la predicción aplicando la transformación y después lo integramos en nuestra serie temporal inicial, de manera que quedaría lo siguiente:



El diagnostico de los errores sería el siguiente:



- En el grafico superior izquierda, a primera vista, no detectamos ninguna estructura, en la distribución de los errores de los siniestros. Cosa que se tiene que cumplir, para que predicción sea válida.
- En el grafico inferior izquierda, si que vemos que los residuos sí que se aproximan a una distribución normal, salvo en los extremos. Esto también implica que tenemos una buena predicción
- En el grafico superior derecha, si que vemos que hay diferencia entre las dos curvas. La curva verde (Kernel Density Estimation) debería estar más próxima a la curva roja que es una normal(0,1).
- En el grafico inferior derecha, vemos un correlograma donde salvo el primer valor, el resto debería quedar por debajo de la línea azul. Ya que eso demuestra que la autocorrelación es cercana a 0 o nula y efectivamente vemos, que eso es lo que ocurre.

Conclusión: es posible que el modelo sea mejorable, pero según lo visto ahora y las predicciones sí que tenemos un modelo bastante fiable.


5.4. Efecto Covid en la serie temporal

La base de datos de 2020, no se ha tenido en cuenta en el análisis, porque según la fuente de los datos, los datos hasta dentro de unos meses no son definitivos. Ello podría producir que los análisis que fueran a hacerse de la información no fueran fiables.

Sin embargo, en este apartado queremos ver el efecto que ha tenido el confinamiento en marzo, abril y mayo, en el número de accidentes y es por eso que vamos a tratar la info de 2020 para añadirla a la serie temporal, solo con este fin.

El objetivo será comparar lo que se habría predicho en nuestra predicción del modelo de serie temporal hasta justo antes del confinamiento y compararlo con lo que realmente ocurrió con el número de accidentes durante el estado de alarma.

De un primer vistazo, vemos la evolución del número de accidentes sin ilesos, durante el 2020:



Efectivamente y como se podría esperar, en algún punto entre el 1 de marzo y el 22 de marzo, se ve claramente una bajada en el número de accidentes.


Vamos a separar ahora el DataSet de 2020 en dos:

- Antes o el día 29 de febrero.
- Después del 1 de marzo

La primera parte la integraremos a la serie del número de accidentes ya utilizada en apartados anteriores. La segunda parte, la compararemos con lo predicho con el modelo de serie temporal que integra todo el evolutivo anterior.

Es cierto y sería lógico, separar el dataset el día 14 de marzo, pero la predicción que se ha hecho en apartados anteriores es mensual y si separamos el mes de marzo en dos partes, la estimación no será correcta porque el acumulado mensual de marzo quedaría incompleto.

A continuación, observamos cual sería la predicción y cuáles fueron los datos reales de accidentes durante el confinamiento:



La línea azul, es lo ocurrido hasta febrero de 2020, la línea roja es lo predicho y la línea verde es lo que realmente ocurrió durante el confinamiento.

Solo ha habido tres periodos mensuales de confinamiento que podemos comparar con la predicción que se ha hecho de la serie, pero podemos ver de manera muy clara, que el número de accidentes de tráfico en los meses de confinamiento ha bajado y que como es lógico la predicción no pudo anticipar que esta bajada fuera a ocurrir.

La predicción del número de accidentes hubiera sido bastante acertada, sino hubiera ocurrido el evento Covid. Es por ello, que podemos obtener la siguiente conclusión: los modelos pueden ayudarnos a predecir lo que puede ocurrir, pero no podemos fiarnos ciegamente en ellos. Hay variables que pueden afectar a nuestro modelo y pueden cambiar totalmente nuestra predicción.

6. Visualización de los puntos de concentración de accidentes

El propósito de este epígrafe es:

- Visualizar la localización de los puntos de concentración de accidentes mortales, que han tenido fallecidos, con el fin de detectar si hay tramos donde se concentren accidentes en las carreteras/calles de Madrid y donde se sitúan.
- Visualizar la localización de los puntos donde se encuentran los radares situados en Madrid.
- Cruzar la localización de ambos tipos de puntos, con el fin de saber si el posicionamiento de los radares se establece de acuerdo con la posibilidad o no de que ocurran accidentes mortales.

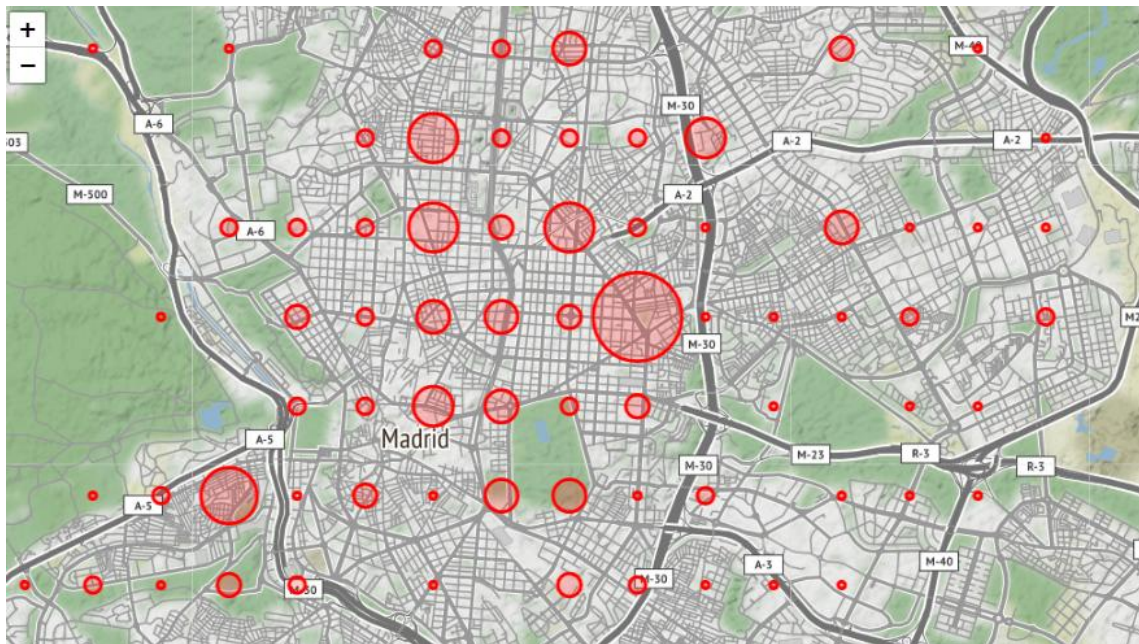
6.1. Visualización de los puntos de concentración de accidentes

Para llegar a tener la visualización, se han tenido que seguir los siguientes pasos:

- Se utiliza la API de Google introduciendo la variable 'Dirección' del DataSet de los accidentes donde la lesividad tiene la categoría de fallecido, con el fin de que la Api nos devuelva la latitud y longitud.
- Una vez obtenidas las coordenadas, con la librería Folium, visualizamos en un mapa, las localizaciones.


En un primer momento, se geolocalizó por puntos los accidentes mortales en Madrid, pero solo es útil esta visualización, si queremos ver todos los accidentes. Pero lo que nos interesa es saber si ha habido algún tramo donde se concentren los accidentes. Es por ello, que se redondeo las latitudes y longitudes, hasta dos decimales. De esta manera, podremos agrupar zonas de accidentes en áreas homogéneas y ver donde se concentran más los accidentes.

Esta es una parte de la visualización de la geolocalización.



Nota: Para ver de una manera más precisa la visualización, abrir el notebook 'Geolocalización'.

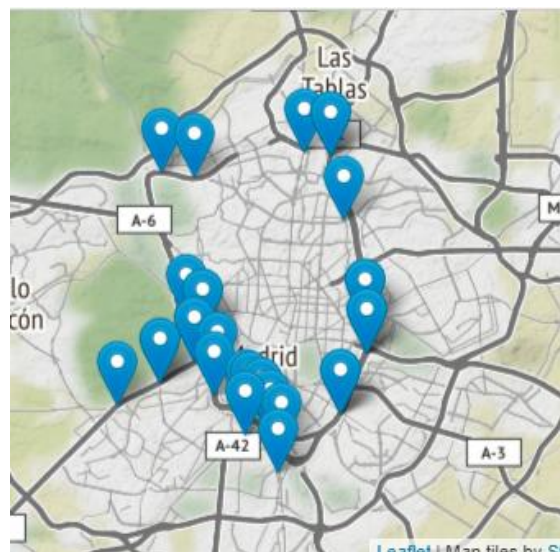
Consideraremos punto negro, aquel que tenga 5 o más accidentes mortales. De manera que, vemos que hay 8 zonas donde se concentra accidentes mortales:



Destaca una zona de Madrid por su concentración de accidentes mortales y es el barrio de Guindalera, teniendo un total de 11 accidentes mortales.

6.2. Visualización de la localización de radares

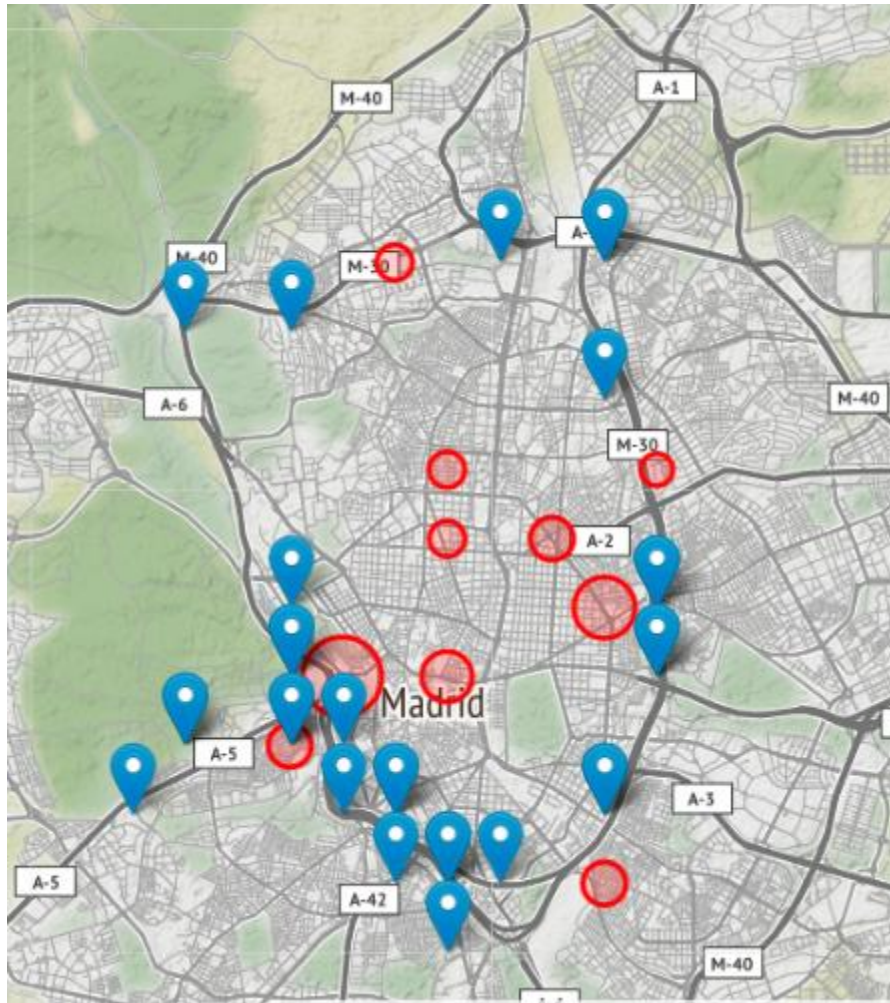
Se realiza la visualización de la localización de los radares.



Nota: Para ver de una manera más precisa la visualización, abrir el notebook 'Geolocalización'.

6.3. Visualización conjunta de los puntos de concentración de accidentes y radares

Vemos conjuntamente, los puntos de concentración de accidentes mortales y radares.



Conclusión: de los puntos de concentración de accidentes mortales (más de 5 accidentes mortales), solo uno se encuentra cerca de los radares. Por lo que no podemos determinar que la decisión a la hora de establecer un radar, sea la geolocalización de los accidentes mortales.

7. Conclusiones

Los temas que se han tenido entre manos en este TFM, han sido en general poder conocer mas sobre la conducción en Madrid y específicamente poder predecir el número de accidentes y comparar la localización de los radares con los puntos de concentración de accidentes.

Con respecto al conocimiento general, con las visualizaciones en Tableau y del trabajo derivado del tratamiento de los datos se ha conseguido este fin. Señalar, que desde mi punto de vista el comportamiento de las variables no me ha supuesto una sorpresa.

Con respecto a la predicción del número de accidentes, aunque parecía que la predicción si parecía bastante fiable, esta finalmente ha sido errónea. Ha sido bastante lógico que esto fuera así, ya que el shock que ha supuesto el Covid19, era muy difícil de predecir. Como ya se

comento anteriormente, esto es una prueba de que no nos podemos fiar ciegamente en los modelos y de que tenemos que tener en cuenta que puede haber errores en la predicción.

Por último, con respecto a la localización de los puntos de concentración de accidentes, ha sido posible obtenerla y compararla con la localización de los radares. Pudiendo, como ya se ha comentado, dar la conclusión de que no hay evidencia de que la ubicación de los radares se establezca según la localización de los puntos de concentración de accidentes.